

Học Sâu cho Khoa Học Dữ liệu

Chapter 1. A Review of Machine Learning Fundamentals

Hà Minh Tuấn

`hmtuan@hcmus.edu.vn`

Khoa Toán - Tin học

Trường Đại học Khoa học Tự nhiên, ĐHQG-HCM

Ngày 4 tháng 3 năm 2026


Nội dung bài học

1. What is Deep learning?
2. Trích xuất Đặc trưng Tự động
3. Perceptron Forward Propagation
4. Ví dụ minh hoạ

Mối quan hệ giữa AI, ML và Deep Learning

Định nghĩa

Deep Learning (Học sâu) là một tập con chuyên biệt của Machine Learning, và Machine Learning là một nhánh quan trọng thuộc lĩnh vực Trí tuệ nhân tạo (AI).



Teaching computers how to **learn a task** directly from **raw data**

Tiến trình phát triển

- **Giai đoạn khởi đầu:** Mạng nơ-ron đã tồn tại hơn 50 năm nhưng bị hạn chế bởi sức mạnh tính toán và dữ liệu.
- **Sự bùng nổ (Early 2000s):** Sức mạnh tính toán tăng theo cấp số nhân dẫn đến một “cuộc bùng nổ kỷ Cambri” về kỹ thuật tính toán.
- **Sự thống trị:** Deep Learning trở kỹ thuật hiện đại trong các nhiệm vụ phức tạp và sau khi giành chiến thắng tại nhiều cuộc thi Machine Learning quan trọng và hiện diện trong mọi ngóc ngách của lĩnh vực này.

1. Big Data

- Larger Datasets
- Easier Collection & Storage

IMAGENET



WIKIPEDIA
The Free Encyclopedia



2. Hardware

- Graphics Processing Units (GPUs)
- Massively Parallelizable



3. Software

- Improved Techniques
- New Models
- Toolboxes



Về Deep Learning

Định nghĩa

Deep Learning được định nghĩa là các mạng nơ-ron có số lượng lớn tham số và lớp, vượt xa các phong cách mạng lưới truyền thống trước đây.

- **Bốn kiến trúc cơ bản được tập trung nghiên cứu:**

- ➊ Mạng không giám sát được huấn luyện trước (Unsupervised pretrained networks).
- ➋ Mạng nơ-ron tích chập (Convolutional Neural Networks - CNNs).
- ➌ Mạng nơ-ron hồi quy (Recurrent Neural Networks - RNNs).
- ➍ Mạng nơ-ron đệ quy (Recursive Neural Networks).

Ưu điểm vượt trội của Deep Learning

Định nghĩa: Feature Extraction

Đây là quá trình mạng lưới tự quyết định những đặc điểm nào của tập dữ liệu có thể được sử dụng làm chỉ số để dán nhãn dữ liệu một cách tin cậy.

- **ML truyền thống:** Chuyên gia phải dành hàng tháng hoặc hàng năm để thiết kế các bộ đặc trưng thủ công.
- **Deep Learning:** Vượt qua các thuật toán truyền thống về độ chính xác với sự điều chỉnh và nỗ lực tối thiểu từ con người.
- **Giá trị thực tiễn:** Giúp các đội ngũ khoa học dữ liệu tập trung vào các nhiệm vụ có ý nghĩa hơn.

Từ Độ chính xác đến Sự sáng tạo

- Deep Learning không chỉ đạt độ chính xác cao mà còn thể hiện "cơ chế sinh" (generative mechanics) đầy ấn tượng.
- Khả năng này thúc đẩy các cuộc thảo luận triết học về bản chất của sự sáng tạo ở máy móc.

Ví dụ: Art Generation (Gatys et al., 2015)

Mạng lưới sâu được huấn luyện trên tác phẩm của các họa sĩ nổi tiếng có khả năng tái hiện lại bất kỳ bức ảnh nào theo phong cách hội họa độc đáo của họa sĩ đó.

Xử lý Dữ liệu thô đa dạng

- **Machine Learning truyền thống:** Đòi hỏi tiền xử lý tỉ mỉ để biến văn bản, âm thanh, hình ảnh thành các véc-tơ số nhằm giải hệ phương trình $Ax = b$.
- **Sức mạnh của Deep Learning:**
 - ▶ Các kiến trúc như CNN (mạng tích chập) hay RNN (mạng hồi quy) có thể tiếp nhận trực tiếp dữ liệu phức tạp.
 - ▶ Tự tìm ra các cấu trúc biểu diễn thông tin hiệu quả nhất mà không cần sự can thiệp sâu của con người vào giai đoạn thiết kế.

Trích xuất đặc trưng tự động

Định nghĩa

Trích xuất đặc trưng tự động là quá trình mạng nơ-ron tự quyết định những đặc điểm nào của tập dữ liệu có thể được sử dụng làm chỉ số để dán nhãn dữ liệu một cách đáng tin cậy.

- Đây là một trong những lợi thế lớn nhất của Deep Learning so với các thuật toán Machine Learning truyền thống.
- Thay vì con người phải can thiệp về mặt kỹ thuật, mạng lưới tự học cách biểu diễn dữ liệu thô thông qua các lớp và tham số.
- Quá trình này giúp giảm thiểu đáng kể sự can thiệp thủ công và tinh chỉnh từ phía con người.

Sự vượt trội so với Machine Learning truyền thống

Định lý về hiệu suất

Deep Learning đã vượt qua các thuật toán thông thường về độ chính xác đối với hầu hết mọi loại dữ liệu với nỗ lực con người tối thiểu.

- **Lịch sử:** Các chuyên gia Machine Learning từng phải dành nhiều tháng hoặc nhiều thập kỷ để tạo ra các bộ đặc trưng thủ công nhằm phân loại dữ liệu.
- **Hiện tại:** Các mạng sâu có thể hấp thụ nỗ lực của con người trong hàng thập kỷ bằng cách tự tích lũy các đặc trưng liên quan từ dữ liệu đầu vào.
- **Giá trị:** Điều này giúp các đội ngũ khoa học dữ liệu tiết kiệm công sức cho những nhiệm vụ có ý nghĩa hơn.

Ví dụ minh họa: Chuyển đổi phong cách nghệ thuật

Ví dụ: Nghiên cứu của Gatys và cộng sự (2015)

Một mạng lưới sâu được huấn luyện trên các tác phẩm của một họa sĩ nổi tiếng có khả năng tự trích xuất “phong cách” độc bản của họa sĩ.


- Mạng nơ-ron có thể áp dụng phong cách đã học để tái hiện lại các bức ảnh chụp thông thường theo nét vẽ của họa sĩ.
- Điều này minh họa cho “cơ chế sinh” (generative mechanics) của Deep Learning, nơi máy móc thể hiện khả năng sáng tạo dựa trên các đặc trưng đã trích xuất.
- Ví dụ này cho thấy máy tính có thể nhận diện các mẫu cấu trúc tinh vi trong nghệ thuật mà không cần lập trình quy tắc cụ thể.

Tóm tắt lợi ích

- **Xử lý dữ liệu thô:** Khả năng làm việc trực tiếp với dữ liệu thô như hình ảnh, âm thanh và văn bản.
- **Tính tổng quát hóa:** Tự động tìm ra các cấu trúc ẩn giúp mô hình dự đoán tốt hơn trên dữ liệu mới.
- **Tối ưu hóa nguồn lực:** Giảm bớt gánh nặng thiết kế đặc trưng thủ công cho con người.

Deep Learning: Từ Dữ liệu thô đến Trí tuệ

The Perceptron: Forward Propagation




Output

Linear combination of inputs

$$\hat{y} = g\left(\sum_{i=1}^m x_i w_i\right)$$

Non-linear activation function

The Perceptron: Forward Propagation



Output


Linear combination of inputs

$$\hat{y} = g\left(w_0 + \sum_{i=1}^m x_i w_i\right)$$

Non-linear activation function

Bias

The Perceptron: Forward Propagation




Activation Functions

$$\hat{y} = g(w_0 + \mathbf{x}^T \mathbf{w})$$


- Example: sigmoid function

$$g(z) = \sigma(z) = \frac{1}{1 + e^{-z}}$$



Common Activation Functions


Sigmoid Function



$$g(z) = \frac{1}{1 + e^{-z}}$$

$$g'(z) = g(z)(1 - g(z))$$


Hyperbolic Tangent



$$g(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

$$g'(z) = 1 - g(z)^2$$

Rectified Linear Unit (ReLU)




$$g(z) = \max(0, z)$$

$$g'(z) = \begin{cases} 1, & z > 0 \\ 0, & \text{otherwise} \end{cases}$$

More Common Activation Functions


Leaky ReLU



$$g(z) = \begin{cases} z, & z > 0 \\ \alpha z, & z \leq 0 \end{cases}$$

$$g'(z) = \begin{cases} 1, & z > 0 \\ \alpha, & \text{otherwise} \end{cases}$$


Exponential Linear Unit (ELU)



$$g(z) = \begin{cases} z, & z > 0 \\ \alpha(e^z - 1), & z \leq 0 \end{cases}$$

$$g'(z) = \begin{cases} 1, & z > 0 \\ g(z) + \alpha, & z \leq 0 \end{cases}$$

Softplus



$$g(z) = \ln(1 + e^z)$$

$$g'(z) = \frac{1}{1 + e^{-z}} = \sigma(z)$$

Softmax Activation Function

Định nghĩa

$$g(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}$$


Tính chất

- Đầu ra $\in (0, 1)$ với mọi i
- Tổng xác suất = 1: $\sum_{i=1}^K g(z_i) = 1$
- Khuếch đại giá trị lớn nhất


Đạo hàm

$$\frac{\partial g_i}{\partial z_j} = \begin{cases} g_i(1 - g_i) & i = j \\ -g_i \cdot g_j & i \neq j \end{cases}$$

Ví dụ: Input vector $\mathbf{z} \rightarrow$ Output $g(\mathbf{z})$




$$g(z_i) = e^{z_i} / \sum e^{z_j}$$



Dùng cho lớp **Output** của bài toán phân loại đa lớp (multi-class classification)


Multi Output Perceptron

*Because all inputs are densely connected to all outputs, these layers are called **Dense** layers*



$$z_{\mathbf{i}} = w_{0,\mathbf{i}} + \sum_{j=1}^m x_j w_{j,\mathbf{i}}$$


Single Layer Neural Network



$$z_i = w_{0,i}^{(1)} + \sum_{j=1}^m x_j w_{j,i}^{(1)}$$

$$\hat{y}_i = g\left(w_{0,i}^{(2)} + \sum_{j=1}^{d_1} g(z_j) w_{j,i}^{(2)}\right)$$

Deep Neural Network



Công thức toán tại node trong lớp Hidden

$$z_{k,i} = w_{0,i}^{(k)} + \sum_{j=1}^{n_{k-1}} g(z_{k-1,j}) w_{j,i}^{(k)}$$

Ví dụ: Dự đoán Đậu/Rớt kỳ thi

Bài toán

- **Input** x_1 : Số giờ tham gia lớp học
- **Input** x_2 : Số giờ ôn bài cuối kỳ
- **Output** y : Kết quả thi
 - ▶ $y = 1$: Đậu ●
 - ▶ $y = 0$: Rớt ●


Mục tiêu

Học hàm $\hat{y} = g(w_0 + w_1x_1 + w_2x_2)$ để dự đoán sinh viên đậu hay rớt.

Bảng dữ liệu 10 sinh viên

SV	x_1 (giờ/tuần)	x_2 (giờ ôn)	y
1	2	1	0 ✗
2	1	3	0 ✗
3	3	2	0 ✗
4	2	4	0 ✗
5	4	3	0 ✗
6	5	5	1 ●
7	6	4	1 ●
8	4	7	1 ●
9	7	6	1 ●
10	6	8	1 ●

Minh họa dữ liệu: Đâu/Rớt theo x_1 và x_2



Nhận xét

- Sinh viên **rớt** tập trung ở vùng $x_1 + x_2$ **thấp**
- Sinh viên **đậu** tập trung ở vùng $x_1 + x_2$ **cao**
- Đường **decision boundary** phân tách 2 nhóm

Mô hình học


$$\hat{y} = \sigma(w_0 + w_1x_1 + w_2x_2)$$

Với σ là hàm Sigmoid:

$\hat{y} \approx 1 \Rightarrow$ Đậu


$\hat{y} \approx 0 \Rightarrow$ Rớt

Example Problem: Will I pass this class?



Quantifying Loss


The **loss** of our network measures the cost incurred from incorrect predictions



Empirical Loss

The **empirical loss** measures the total loss over our entire dataset

$$\mathbf{X} = \begin{bmatrix} 4, & 5 \\ 2, & 1 \\ 5, & 8 \\ \vdots & \vdots \end{bmatrix}$$



$f(x)$		y
$\begin{bmatrix} 0.1 \\ 0.8 \\ 0.6 \\ \vdots \end{bmatrix}$	$\times$	$\begin{bmatrix} 1 \\ 0 \\ 1 \\ \vdots \end{bmatrix}$
	$\checkmark$	
	$\vdots$	

Predicted Actual


Also known as:

- Objective function
- Cost function
- Empirical Risk

$$J(\mathbf{W}) = \frac{1}{n} \sum_{i=1}^n \mathcal{L} \left(\underbrace{f(x^{(i)}; \mathbf{W})}_{\text{Predicted}}, \underbrace{y^{(i)}}_{\text{Actual}} \right)$$

Binary Cross Entropy Loss

Cross entropy loss can be used with models that output a probability between 0 and 1




$$J(\mathbf{W}) = -\frac{1}{n} \sum_{i=1}^n \underbrace{y^{(i)}}_{\text{Actual}} \log \left(\underbrace{f(x^{(i)}; \mathbf{W})}_{\text{Predicted}} \right) + \underbrace{(1 - y^{(i)})}_{\text{Actual}} \log \left(\underbrace{1 - f(x^{(i)}; \mathbf{W})}_{\text{Predicted}} \right)$$

Mean Squared Error Loss

Mean squared error loss can be used with regression models that output continuous real numbers

$$\mathbf{X} = \begin{bmatrix} 4, & 5 \\ 2, & 1 \\ 5, & 8 \\ \vdots & \vdots \end{bmatrix}$$



$f(x)$		y
$\begin{bmatrix} 30 \\ 80 \\ 85 \\ \vdots \end{bmatrix}$	$\times$	$\begin{bmatrix} 90 \\ 20 \\ 95 \\ \vdots \end{bmatrix}$
	$\times$	
	$\checkmark$	
	$\vdots$	
Final Grades (percentage)		

$$J(\mathbf{W}) = \frac{1}{n} \sum_{i=1}^n \left(\underbrace{y^{(i)}}_{\text{Actual}} - \underbrace{f(x^{(i)}; \mathbf{W})}_{\text{Predicted}} \right)^2$$

Hết bài!

Hãy sẵn sàng cho hành trình vào thế giới Deep Learning

Tài liệu: Goodfellow, Bengio, & Courville (2016)